Modelo Preditivo para Diagnóstico de Doença Hepática

Análise, Modelagem e Comparação de Algoritmos

Emerson Silva, Cientista de Dados

Problema de Negócio:

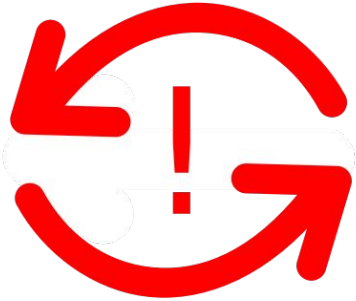

- A doença hepática e o problema na área da saúde pública e privada
- Dificuldade na predição
- Detecção tardia
- Custos dos atuais métodos
- Métodos invasivos e demorados

Emerson Silva, Cientista de Dados

Objetivo:

- Desenvolver e avaliar diferentes modelos de Machine Learning
- Compreender influência das Variáveis Preditoras
- Escolher o melhor modelo preditivo
    - Identificar pacientes com alta probabilidade de possuir uma doença hepática
    - Baseado em variáveis fisiológicas.
- Testar com novos dados

Análise Exploratória

- Outliers a Tratar
  - Total_Bilirubin
  - Direct_Bilirubin
  - Alkaline_Phosphotase
  - Alamine_Aminotransferase
  - Aspartate_Aminotransferase
- Soluções tomadas
  - Remoção de registros a partir de um n“ de corte como sugerido pela equipe

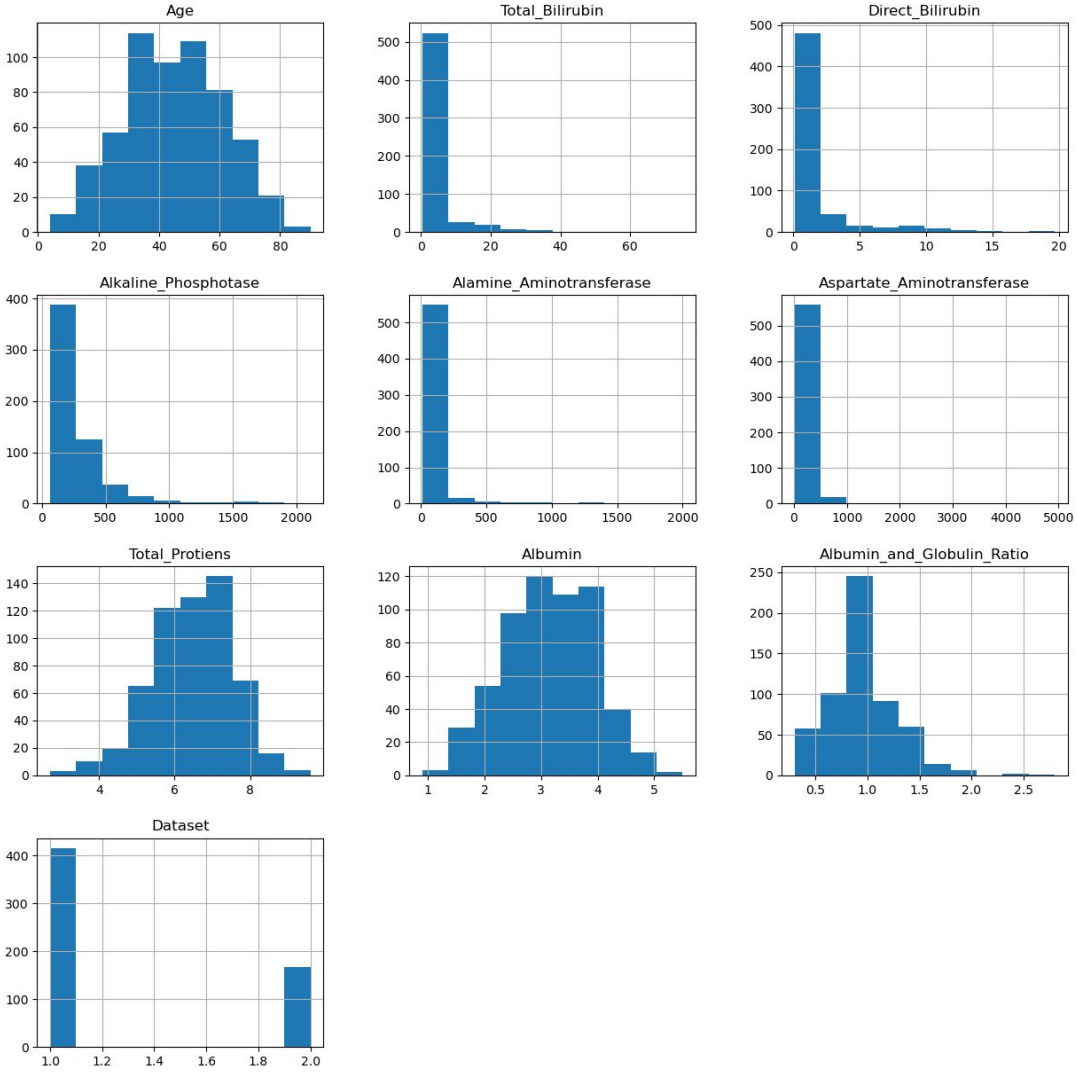

Emerson Silva, Cientista de Dados

Análise Exploratória

- Desbalanceamento de Classes
  - Número de pacientes do sexo masculino: 426 (0)
  - Número de pacientes do sexo feminino: 138 (1)
- Soluções tomadas
  - Oversampling com SMOTE

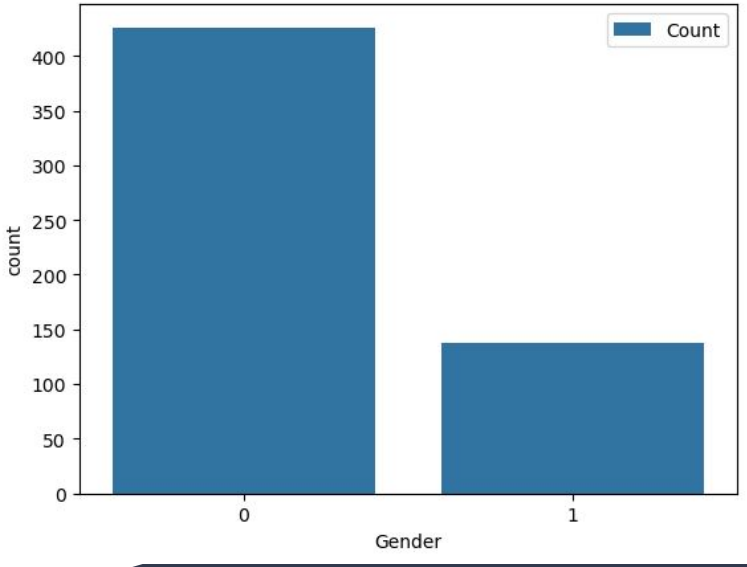

Emerson Silva, Cientista de Dados

Machine Learning

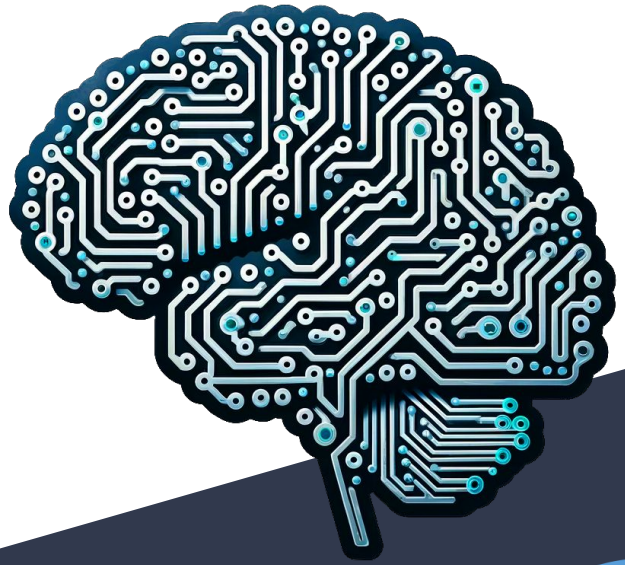

- Divisão para Treino e Teste
  - 75% para Treino
  - 25% para Teste
- Padronização dos Dados

Emerson Silva, Cientista de Dados

Machine Learning

- Modelo V1
  - Regressão Logística
- Modelo V2
  - Random Forest
- Modelo V3
  - KNN
- Modelo V4
  - Decision Tree
- Modelo V5
  - SVM

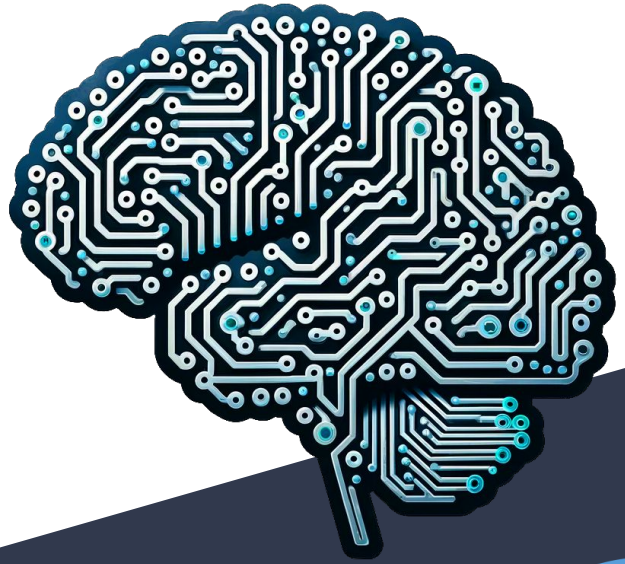

Emerson Silva, Cientista de Dados

Machine Learning

o Random Forest se destacou como o mais eficiente, com um bom equilíbrio entre complexidade computacional e desempenho preditivo.

A Acurácia foi de 0.744, sugerindo que o modelo tem uma taxa de sucesso razoável na classificação correta dos casos.

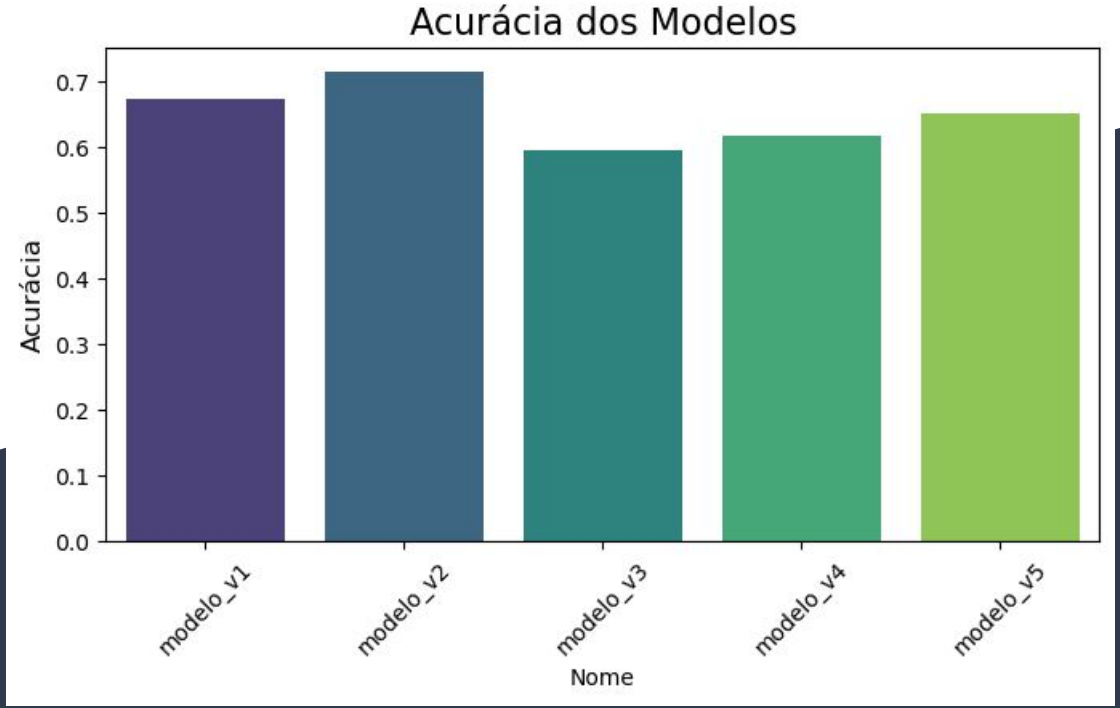

Emerson Silva, Cientista de Dados

Machine Learning

Cada curva mostra a relação entre Falsos Positivos e Verdadeiros Positivos

O valor AUC indica a qualidade do modelo

O modelo Random Forest obteve AUC de 0.754, indicando uma boa capacidade de discriminação entre pacientes com e sem risco de doença hepática.

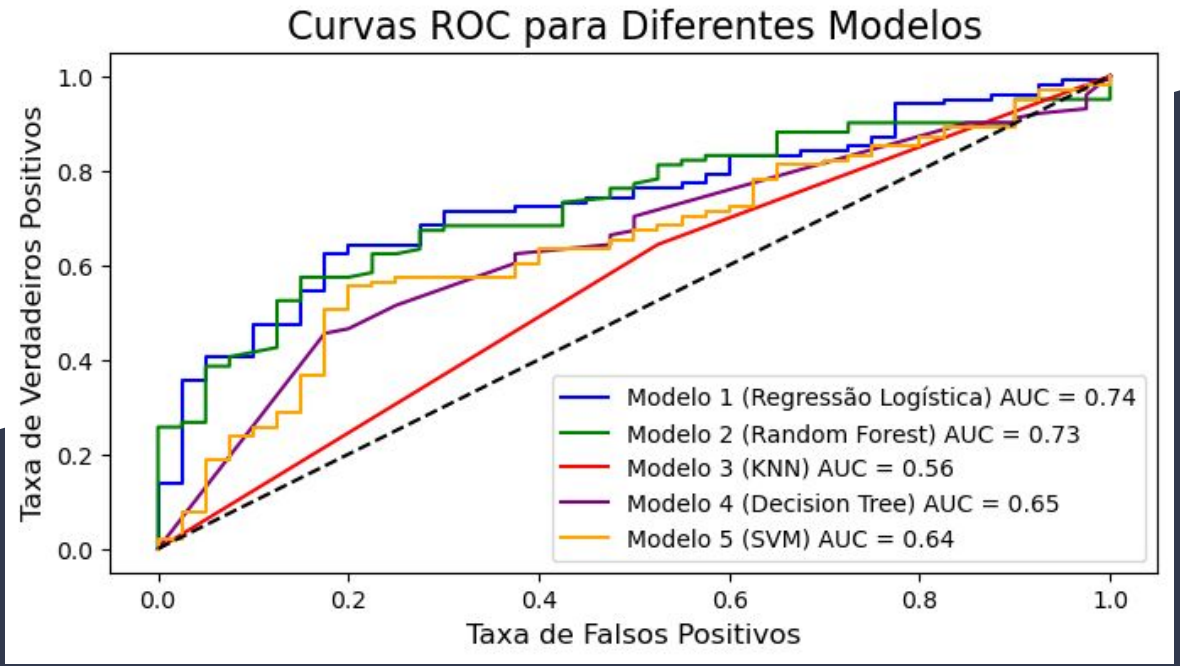

Feature Importance

As métricas de importância das variáveis ajudam a identificar quais fatores fisiológicos influenciam mais a classificação.

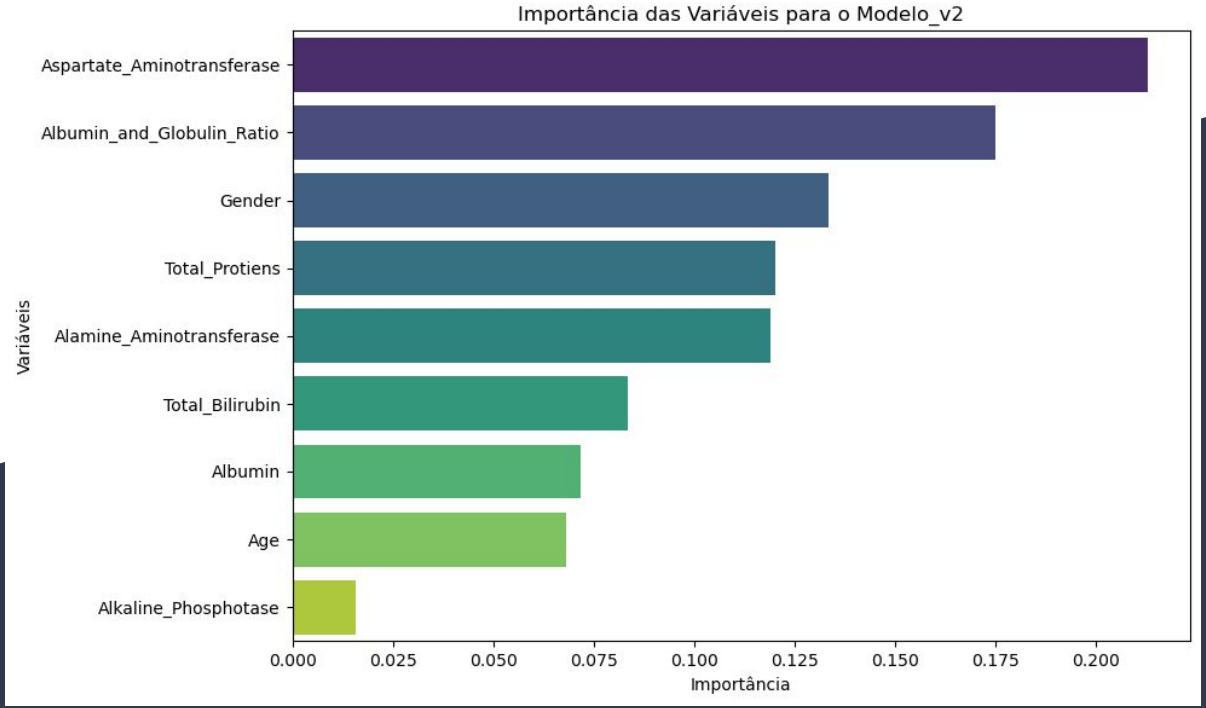

Testando o Modelo com Novos Dados

Um exemplo de um novo paciente foi classificado utilizando o modelo de Random Forest.

A probabilidade de desenvolver a doença hepática foi predita com base nas características fornecidas, com um resultado indicando a presença de risco para doença hepática.

Novas Previsões com o Random Forest

```
# Novo paciente
novo_paciente = [72, 1, 0.8, 186, 15, 29, 7.1, 3.4, 0.97]
```

```
# Conv. em array
arr_paciente = np.array(novo_paciente)
```

```
# Padronização
arr_paciente = (arr_paciente - treino_mean) / treino_std
```

```
arr_paciente
```

```
Age                          1.756525
Gender                       1.942036
Total_Bilirubin             -0.336404
Alkaline_Phosphotase        -0.366761
Alamine_Aminotransferase    -0.340191
Aspartate_Aminotransferase  -0.344365
Total_Protiens               0.576059
Albumin                      0.200208
Albumin_and_Globulin_Ratio  -0.116449
dtype: float64
```

```
# Converter para array NumPy e redimensionar corretamente
arr_paciente = np.array(arr_paciente).reshape(1, -1)
```

```
# Fazer a previsão
pred_novo_paciente = modelo_v2.predict(arr_paciente)
```

```
# Resultado
if pred_novo_paciente == 1:
    print('Este paciente pode apresentar doença hepática!')
else:
    print('Não há alta probabilidade de apresentar doença hepática!')
```

```
Este paciente pode apresentar doença hepática!
```

Emerson Silva, Cientista de Dados

Aberto a Dúvidas e Sugestões. Muito Obrigado!

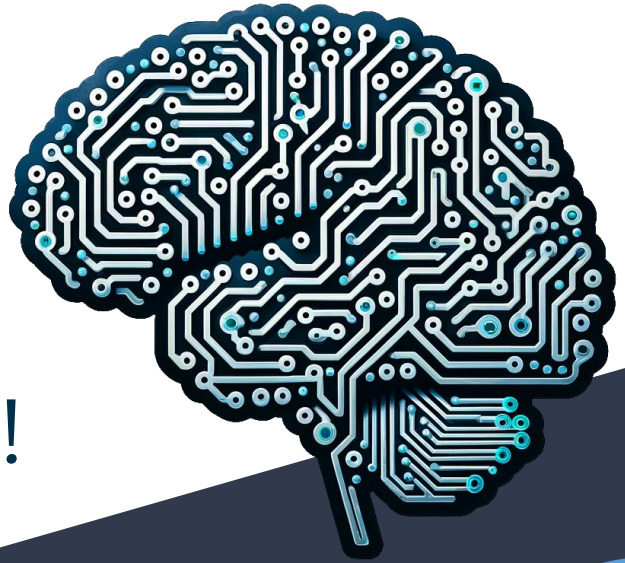

Emerson Silva, Cientista de Dados